

ADR-0001 — Où stocker les commandes clients

Status : Accepté
Date : 06/10/2026

Contexte

L'API reçoit les commandes une par une, écriture puis relecture par identifiant en quelques millisecondes.
L'entraînement du modèle relit tout l'historique d'un coup et doit pouvoir retrouver exactement les données utilisées.

Options considérées

Option	Avantage	Inconvénient
A. PostgreSQL seul	Transactions et lecture par clé immédiates	Lecture massive peu adaptée, pas de retour à un état passé
B. PostgreSQL + export quotidien vers un lakehouse	Chaque usage a l'outil adapté	Deux stockages et un job de copie à maintenir
C. Parquet nu sur S3 + DuckDB	Simple, format ouvert	Un fichier par commande, pas de transactions
D. DuckLake (Parquet sur S3 + catalogue PostgreSQL)	Un seul stockage, transactions, snapshots	Ni PRIMARY KEY , ni UNIQUE , ni CHECK

Décision

Option D : un seul stockage pour l'API et l'entraînement, PostgreSQL comme tampon pour les données récentes, et des snapshots qui rendent chaque entraînement reproductible.

Conséquences

DuckLake n'appliquant aucune contrainte, les contrôles restent dans le code et les doublons sont écartés par une vue placée sur une table brute en ajout seul.