

ADR-0003 — Où déployer l'application

Status : Accepté

Date : 09/10/2026

Contexte

L'API doit être disponible en continu et l'entraînement doit pouvoir être relancé à la demande, au plus près du catalogue PostgreSQL et du stockage S3 retenus dans l'ADR-0001 : relire une commande déjà écrite en Parquet doit rester rapide.

Le projet a un budget limité et une seule personne pour l'exploiter.

Options considérées

Option	Avantage	Inconvénient
A. PaaS managé (Render, Railway, Fly.io)	Aucun serveur à administrer	Coût qui augmente à chaque service, mise en veille des offres gratuites
B. Cloud public (Cloud Run, AWS ECS)	Mise à l'échelle automatique, services managés	PostgreSQL et S3 managés à payer en plus, facture à l'usage difficile à prévoir, dépendance au fournisseur
C. Kubernetes (k3s) sur un VPS	Orchestration standard et portable	Trop lourd pour une seule API sur un seul serveur
D. VPS netcup (4 vCPU, 8 Go de RAM, 256 Go, Debian 13) + Coolify	Coût fixe ; PostgreSQL, Garage (S3) et Redpanda déjà en place ; build et HTTPS gérés par Coolify	Un seul serveur, pas de mise à l'échelle automatique, exploitation à notre charge

Décision

Option D : l'application tourne sur le VPS, à côté de ses données, pour un coût fixe. Coolify construit l'image, la déploie et la sert en HTTPS.

Conséquences

L'application est livrée sous forme d'image Docker, ce qui permet de passer à l'option B si la charge l'exige.

Le serveur est partagé avec d'autres projets : le conteneur reçoit une limite de mémoire, et les mises à jour et sauvegardes du VPS restent à notre charge.