

ADR-0005 — Quelle stratégie de déploiement



Status : Accepté
Date : 09/10/2026

Contexte

L'application est une seule API, qui tourne en un seul conteneur sur le VPS (ADR-0003). Chaque mise en production ne doit ni couper l'API ni perdre de commande, et une version défaillante doit pouvoir être retirée en quelques minutes.

Le serveur est partagé et limité à 8 Go de RAM : on ne peut pas y faire tourner plusieurs copies complètes de l'application en permanence.

Options considérées

Option	Avantage	Inconvénient
A. Big Bang Release	Simple : on arrête l'ancienne version, on démarre la nouvelle	Coupure à chaque mise en production, aucun filet en cas d'échec
B. Déploiement par service	Chaque service évolue à son rythme	Une seule API : rien à découper
C. Déploiement pilote	Nouvelle version testée par un groupe d'utilisateurs choisi	L'API ne connaît pas ses clients : pas de groupe à cibler
D. Canary Release	Nouvelle version exposée à une petite part du trafic	Plusieurs instances et un routage pondéré ; aucune métrique pour juger le canari avant <code>/metrics</code>
E. Blue / Green	Bascule instantanée et retour arrière immédiat	Deux environnements complets en permanence, trop lourd pour le VPS
F. Shadow	Nouveau modèle testé sur le trafic réel sans répondre aux clients	Deuxième instance et historique des prédictions pour comparer, pas encore disponibles
G. Rolling	Nouvelle version démarrée à côté de l'ancienne, trafic basculé seulement si elle est prête, natif dans Coolify	Les deux versions tournent ensemble quelques secondes

Décision

Option G : chaque mise en production est un rolling update de Coolify. Le nouveau conteneur démarre, Coolify attend que `/health/ready` réponde 200 (modèle chargé, stockage joignable), puis bascule le trafic et arrête l'ancien. Si la nouvelle version n'est jamais prête, l'ancienne continue de servir.

Conséquences

`/health/ready` devient le healthcheck de Coolify, il ne doit répondre 200 que lorsque l'API peut vraiment traiter une requête.

Pendant la bascule, deux versions écrivent dans DuckLake en même temps, ce que le catalogue PostgreSQL supporte. Une nouvelle version doit donc rester compatible avec le schéma de l'ancienne.